

PINNs ■ Burgers 2D ■ problema inverso

# Identificación de parámetros

en la ecuación de Burgers 2D

mediante redes neuronales informadas por la física

Juan Jose Salazar Bedoya  
Cristian Camilo Victoria Parra

Análisis Numérico  
16 de junio de 2026




Figura base del paper: formación del flujo rotacional.

## Primera parte: problema y método

- ➊ Problema físico e idea del paper.
- ➋ Ecuación de Burgers 2D.
- ➌ Qué reproduce el notebook.
- ➍ Cómo se entrena: PINN vs data-driven.

## Segunda parte: resultados

- ➎ Comparaciones paper vs notebook.
- ➏ Extensión: reducción computacional.
- ➐ Validación y limitaciones.
- ➑ Conclusiones.

# Qué pedía el proyecto y qué se hizo

## Pauta del proyecto

- Reproducir un resultado central del paper.
- Hacer una extensión propia.
- Validar con tres controles: referencia, sensibilidad y plausibilidad física.

## En este trabajo

- Se reproduce la metodología con la ecuación de Burgers 2D.
- Se ejecuta en modo demo por costo computacional.
- La extensión es estudiar el efecto de reducir la escala.

# Problema físico: campo de velocidades

## Qué se estudia

- Un fluido en el cuadrado  $[0, 1] \times [0, 1]$ .
- En cada punto hay una velocidad:

$$\mathbf{u}(x, y, t) = (u(x, y, t), v(x, y, t)).$$

- El campo cambia con el tiempo.

## Por qué es inverso

Se tienen datos parciales del campo y se quieren recuperar los parámetros físicos  $\alpha$  y  $\nu$ .






Figura del notebook: evolución de  $u(x, y, t)$ .

# Comparación visual: figura 1 del paper vs notebook

Paper



Notebook demo



**Idea clave:** Ambas figuras muestran estructuras asociadas al flujo rotacional, pero en el notebook son menos limpias por la reducción de malla y pasos temporales.

# Ecuación de Burgers 2D

## Ecuación usada en el paper

$$\mathbf{u}_t + \alpha(\mathbf{u} \cdot \nabla)\mathbf{u} - \nu \Delta \mathbf{u} = 0, \quad \mathbf{u} = (u, v).$$

### Convección: $\alpha$

Representa el transporte por el propio flujo. Si domina, el campo puede cambiar de forma más brusca.

### Difusión: $\nu$

Representa el efecto viscoso. Si  $\nu$  es pequeño, la solución se suaviza menos y el problema se vuelve más difícil.

## Condiciones iniciales

$$u(x, y, 0) = \sin(6\pi y)x(1 - x), \quad v(x, y, 0) = -\sin(6\pi x)y(1 - y).$$

## Condiciones de frontera

Frontera homogénea: la velocidad se anula en el borde.

$$u_\theta = x(1 - x)y(1 - y)NN_u, \quad v_\theta = x(1 - x)y(1 - y)NN_v, \quad \text{donde } x = 0, x = 1, y = 0, y = 1 \implies u_\theta = v_\theta = 0.$$

# Formulación PINN: qué aprende la red

## Entrada y salida

$$(x, y, t) \mapsto \mathbf{u}_\theta(x, y, t) = (u_\theta, v_\theta).$$

La red intenta aproximar el campo de velocidades completo.

## Frontera dura

$$u_\theta = x(1-x)y(1-y)NN_u,$$

$$v_\theta = x(1-x)y(1-y)NN_v.$$

Con este factor, la frontera se cumple automáticamente.

## Pérdida total

$$L = \lambda_{PDE} L_{PDE} + \lambda_{IC} L_{IC} + \lambda_{Data} L_{Data}.$$

- $L_{PDE}$ : respeta la ecuación.
- $L_{IC}$ : respeta el inicio.
- $L_{Data}$ : se ajusta a observaciones.

# Paper vs notebook: escala de datos

| Elemento            | Paper              | Notebook demo          |
|---------------------|--------------------|------------------------|
| Malla espacial      | $256 \times 256$   | $48 \times 48$         |
| Tiempos             | 72                 | 24                     |
| $t_{final}$         | 0.5                | 0.5                    |
| Puntos por solución | 4,718,592          | 55,296                 |
| Referencia          | Volúmenes finitos  | FiPy reducido          |
| Objetivo            | Benchmark completo | Reproducción didáctica |

## Lectura

- Misma ecuación.
- Menor escala de datos.
- Menor costo computacional.
- Mayor error esperado.

**Idea clave:** El notebook reproduce la idea del paper, pero no reproduce su escala completa.



# Paper vs notebook: entrenamiento

## PINN inversa

| Elemento     | Paper       | Demo        |
|--------------|-------------|-------------|
| Ancho de red | 256         | 80          |
| Profundidad  | 10          | 4           |
| Pasos PINN   | 100000      | 1500        |
| Batch IC     | 1024        | 256         |
| Batch EDP    | 2048        | 512         |
| Opt. EDP     | Adam/Newton | Adam/Newton |

## Método data-driven

| Elemento     | Paper | Demo |
|--------------|-------|------|
| Ancho de red | 256   | 80   |
| Profundidad  | 10    | 4    |
| Pasos        | 50000 | 1500 |
| Batch datos  | 2048  | 512  |
| Batch IC     | 2048  | 256  |
| Batch EDP    | 8192  | 512  |

**Idea clave:** La red demo es más pequeña y entrena mucho menos; por eso los resultados no tienen que igualar los del paper.

# Dos formas de entrenar

## PINN

- Usa datos observados.
- Usa condición inicial.
- Usa la ecuación durante el entrenamiento.

$$L = \lambda_{PDE} L_{PDE} + \lambda_{IC} L_{IC} + \lambda_{Data} L_{Data}.$$

## Data-driven fitting

- Primero ajusta datos.
- Después estima parámetros usando la EDP.
- La física entra después, no durante todo el ajuste.

$$L \approx L_{Data} + L_{IC}.$$


**Idea clave:** La PINN intenta parecerse a los datos y respetar la ecuación al mismo tiempo.

# Primer resultado: corrida individual

## Configuración

- $\alpha = 2,0$ .
- $\nu = 10^{-4}$ .
- $N_{data} = 256$ .
- Modo demo.

| Cantidad       | Valor   |
|----------------|---------|
| $\hat{\alpha}$ | 1.1372  |
| $\hat{\nu}$    | 0.02854 |
| Error $\alpha$ | 0.4314  |
| Error $\nu$    | 0.6139  |
| Error solución | 0.7798  |



Evolución de pérdidas durante el entrenamiento.

**Idea clave:** Es un caso difícil porque  $\alpha/\nu = 20000$ ; sirve para verificar el pipeline, no para igualar el paper.

# Comparación numérica: tabla del paper vs notebook

| Opt.   | $E_{\alpha}^p$ | $E_{\alpha}^n$ | $E_{sol}^p$ | $E_{sol}^n$ | $E_{\nu}^p$ | $E_{\nu}^n$ |
|--------|----------------|----------------|-------------|-------------|-------------|-------------|
| Adam   | 0.080          | 1.135          | 0.152       | 0.980       | 0.093       | 0.767       |
| Newton | 0.086          | 7.300          | 0.150       | 0.875       | 0.056       | 0.553       |

Comparación para  $N_{data} = 2048$ .  $p$ : paper;  $n$ : notebook.



## Qué se observa

- Los errores demo son mayores.
- Newton mejora un poco  $\nu$ .
- $\alpha$  queda muy sensible en modo demo.

## Lectura correcta

No es una contradicción del paper: muestra el costo de bajar la escala.


# Comparación visual 1: PINN vs data-driven



**Idea clave:** En el paper las PINNs suelen recuperar mejor parámetros; en demo algunos puntos data-driven salen mejor por la escala reducida.


# Comparación visual 2: método data-driven

Paper: figura 3




Notebook demo: figura 3

Figure 3 — Data-driven estimation



**Idea clave:** La versión demo solo llena los paneles con datos disponibles; por eso no reproduce toda la grilla del paper.

# Comparación visual 3a: parámetros en el paper




Paper: errores de estimación de  $\nu$  y  $\alpha$  con Adam y Newton.

**Idea clave:** En la escala completa, los errores quedan cerca del umbral del 10 % en varios casos, aunque los regímenes menos viscosos siguen siendo más difíciles.

# Comparación visual 3b: parámetros en el notebook

Figure 4 — PINN parameter estimation errors




**Notebook demo: errores de estimación de  $\nu$  y  $\alpha$  con Adam y Newton.**

**Idea clave:** Al bajar la escala, la estimación de parámetros se vuelve menos estable, especialmente para  $\alpha$ .




# Comparación visual 4: error relativo de la solución

Paper: figura 5



Notebook demo: figura 5

Figure 5 — PINN solution relative error



**Idea clave:** El notebook mantiene la estructura de la comparación, pero los errores de solución quedan mucho más altos.

# Extensión: qué se pierde al reducir la escala

## Extensión realizada

Se analiza qué pasa cuando la metodología del paper se ejecuta con menor resolución, menor red y menos entrenamiento.

## Lo que se observa

- El experimento corre en Colab.
- Los errores suben bastante.
- La recuperación de  $\alpha$  se vuelve muy sensible.

| Opt.   | $N_{data}$ | Error $\alpha$ | Error $\nu$ |
|--------|------------|----------------|-------------|
| Adam   | 512        | 1.060          | 0.338       |
| Newton | 512        | 0.814          | 0.343       |
| Adam   | 2048       | 1.135          | 0.767       |
| Newton | 2048       | 7.300          | 0.553       |

## Conclusión de la extensión

Bajar la escala ayuda a ejecutar, pero dificulta la identificación de parámetros.

## Tres controles de validación

- 1 Comparación con FiPy mediante error relativo.
- 2 Sensibilidad frente a datos, optimizador y escala.
- 3 Plausibilidad física: más dificultad cuando  $\nu$  baja y  $\alpha/\nu$  sube.

## Limitación principal

La ejecución demo permite correr el experimento, pero no alcanza la precisión de la configuración completa.

## Conclusiones

- Se reprodujo la metodología del paper a menor escala.
- La PINN incorpora la ecuación diferencial al entrenamiento.
- La baja viscosidad hace el problema más difícil.
- Para estimar bien  $\alpha$  y  $\nu$  se necesita mayor escala computacional.

**Gracias**